LEARNING-BASED DATA FUSION

Riconoscimento pedoni con 3 tipi di data fusion

Alessandro La Mantia

Obiettivo: confrontare tre fusioni

no learning-based data fusion

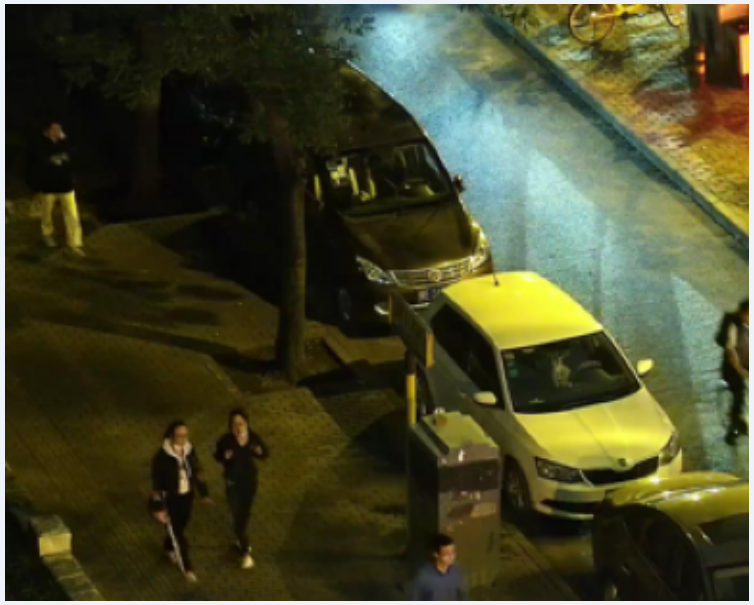
learning-based data fusion

fine tuned learning-based data fusion

Capire se la rete e il fine-tuning aiutano a **riconoscere più pedoni**

rispetto alla no learning-based data fusion

Dataset: AWMM-100K e due tipi di immagini



Visibile: telecamera a colori



Termico: telecamera a infrarossi

AWMM-100K: pretraining. Immagini mostrate: LLVIP, usato nel nostro fine-tuning.

Pioggia artificiale nel nostro esperimento

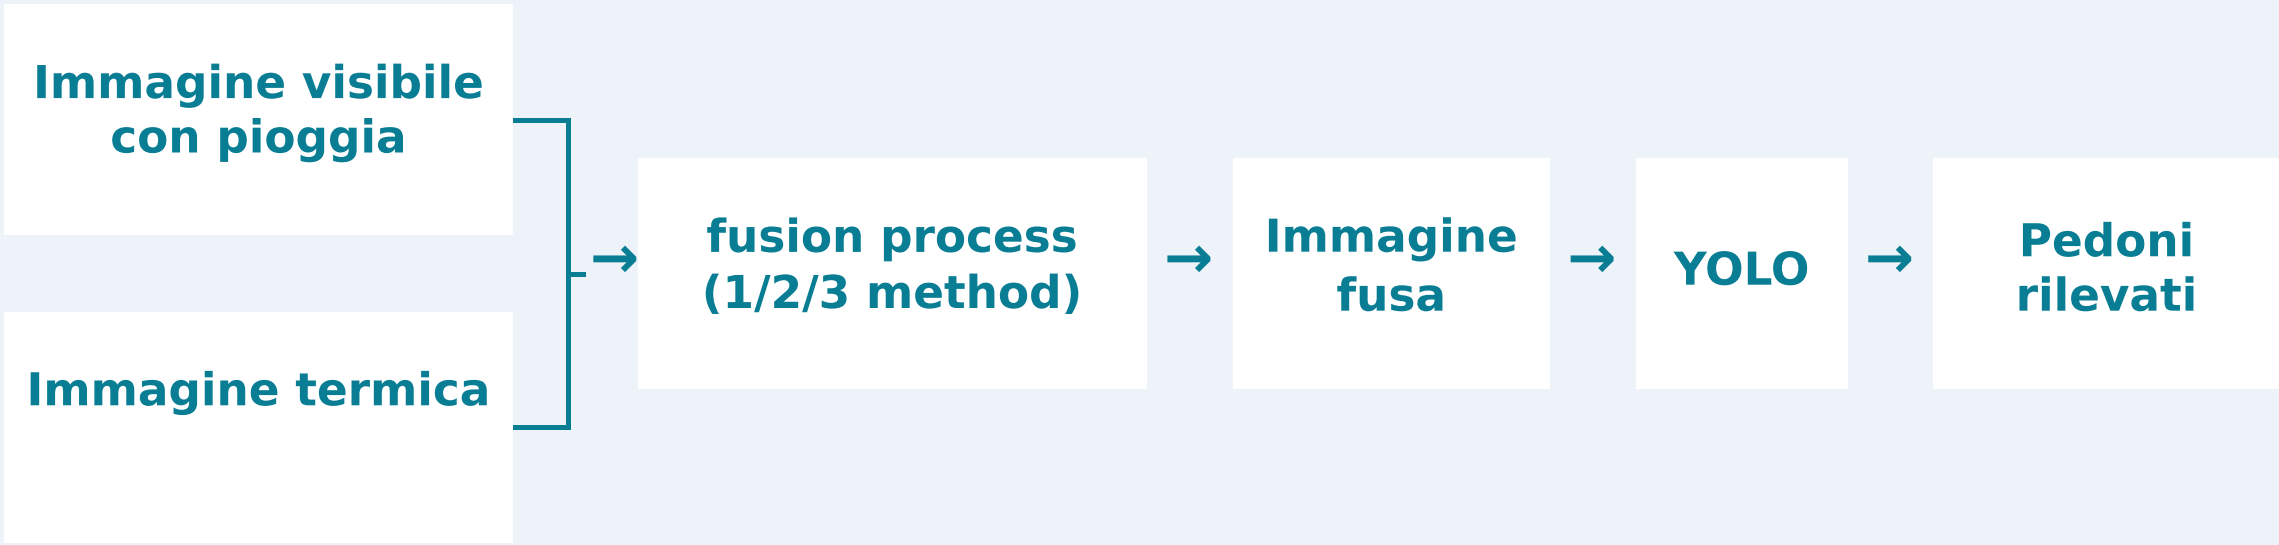
Nel nostro esperimento aggiungiamo pioggia artificiale solo alle immagini della telecamera a colori.



Obiettivo: confrontare i 3 tipi di data fusion tra

immagine con la pioggia e immagine della telecamera a infrarossi

Il percorso completo è questo:



1) No learning-based data fusion

Regola: media dei pixel corrispondenti delle due immagini

$$\text{Immagine fusa} = \frac{\text{Visibile} + \text{Termico}}{2}$$

Ogni pixel riceve metà contributo da ciascuna immagine.
I pesi sono uguali ovunque: la fusione non impara.

2) Learning-based data fusion

- Rete preaddestrata usata: **AMG-Fuse**
- Dataset utilizzato: AWMM-100K con 1.000 coppie di immagini
- AMG-Fuse elabora visibile e termico e produce direttamente un’immagine **R**

1. Estrae feature	→	2. Le combina	→	3. Ricostruisce
Individua contorni e contrasti nei due ingressi.		Unisce le informazioni tramite l’attenzione.		Produce una prima immagine combinata **R**

Come la rete guida la fusione

Il codice prende R e calcola α dopo, confrontandola con i due ingressi.

- R più simile al visibile → α > 0,5 → più contributo del visibile.
- R più simile al termico → α < 0,5 → più contributo del termico.

$$\text{Immagine fusa} = \alpha \times \text{Visibile} + (1 - \alpha) \times \text{Termico}$$

Media fissa: α = 0,5 ovunque. Qui: il peso cambia in base alla scena e alla posizione.

Fine-tuned learning-based data fusion

- Partiamo dalla stessa AMG-Fuse e adattiamo soltanto l’**ultimo strato**
- **Dataset LLVIP**: 100 coppie di immagini
- 3 epoche: **2.592** pesi aggiornati

1. Riconoscimento	→	2. Errore	→	3. Aggiornamento
Immagine fusa → YOLO → riquadri dei pedoni.		Confronto con i riquadri veri presenti nel dataset.		L’errore modifica solo l’ultimo strato della fusione.

YOLO: dalle immagini fuse ai pedoni

Ogni immagine fusa dei tre metodi entra separatamente nello stesso YOLO.

Immagine fusa → YOLO → riquadri dei pedoni + punteggi

Soglia = punteggio minimo per mostrare una rilevazione.

Soglia più alta ↑

Meno rettangoli mostrati.
Può ridurre i falsi allarmi,
ma anche perdere pedoni veri.

Soglia più bassa ↓

Più rettangoli mostrati.
Può recuperare pedoni,
ma anche aggiungere falsi allarmi.

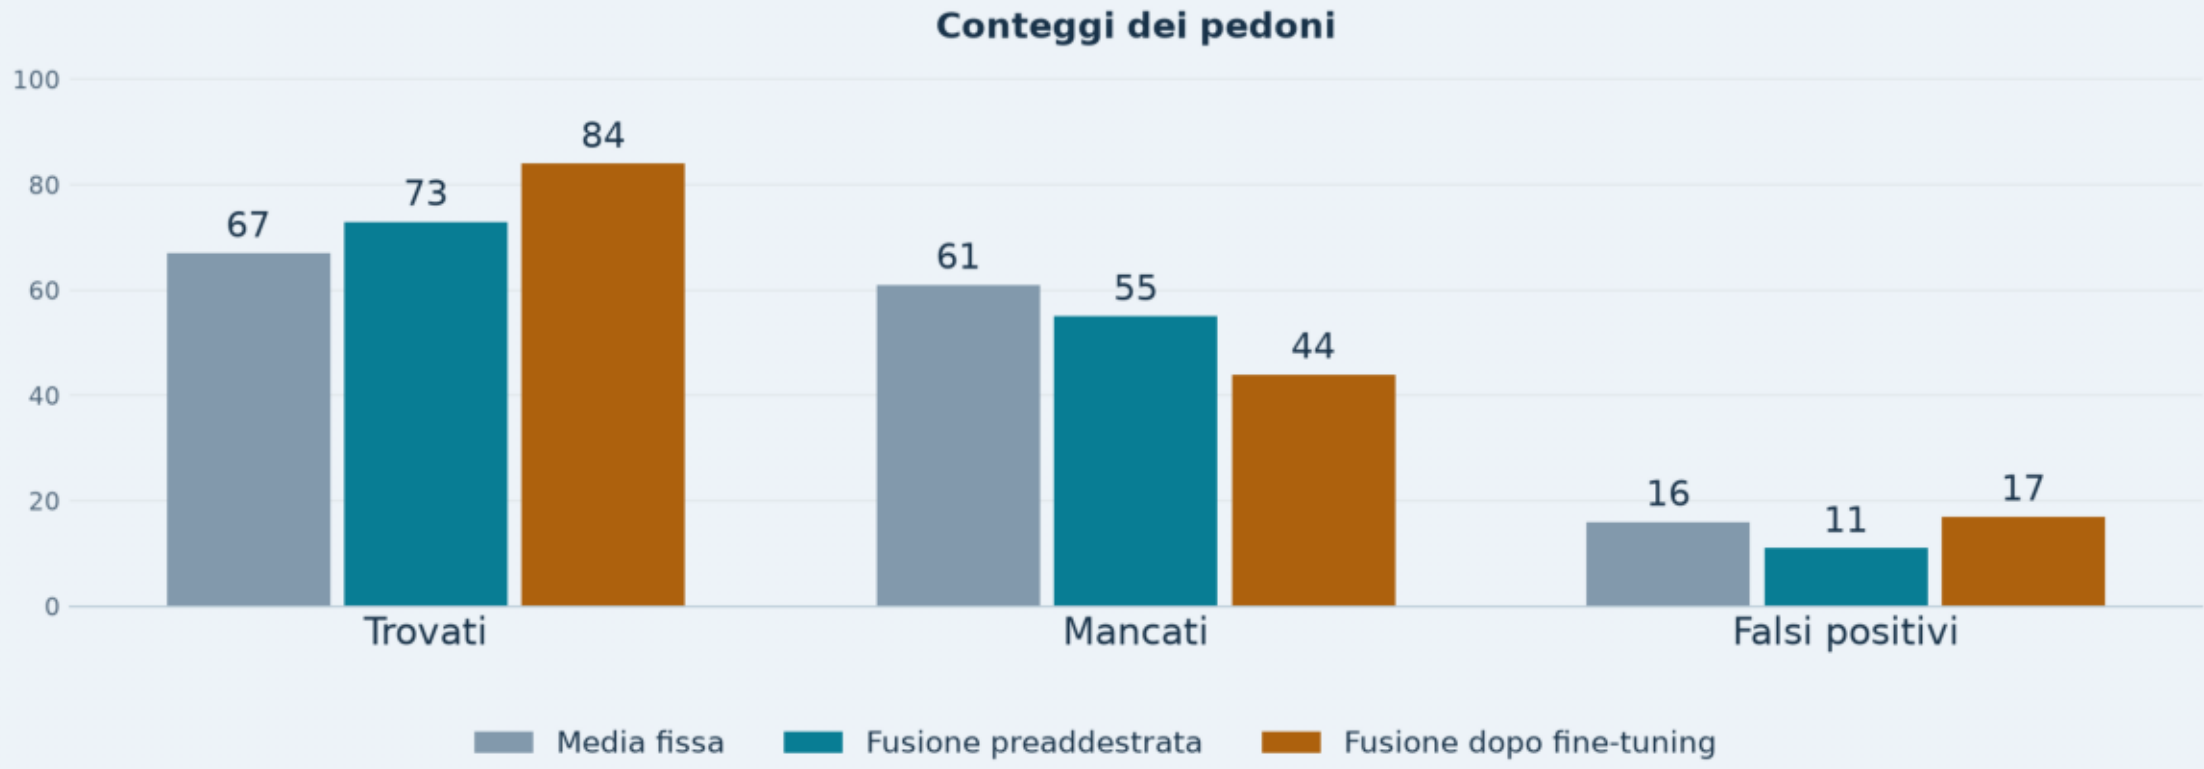
Interfaccia

Ora confrontiamo i tre metodi sulle stesse **50** coppie di immagini test (dataset: LLVIP) usando lo **STESSO YOLO**

http://127.0.0.1:64001

Prestazioni dei tre metodi di fusione

50 coppie LLVIP di test · 128 pedoni annotati · stesso YOLO congelato



Due problemi nella data fusion e le soluzioni

1. Dare lo stesso peso a due immagini di qualità diversa

Ho usato pesi variabili per zona, guidati dalla rete.

2. Rischiare di perdere dettagli dei pedoni

Ho applicato la mappa dei pesi ingrandita alle immagini originali.

Tre cose imparate in questo progetto

1. Combinare due sensori

2. Adattare una rete già addestrata

3. Valutare davvero un miglioramento

Grazie per l'attenzione